


Slide 1: Title

NYC Taxi Data Pipeline

Batch & Streaming Data Engineering Platform



Slide 2: Bài toán


Input

Nguồn	Format	Volume
 NYC TLC Yellow Taxi (S3 Parquet)	Hive-partitioned	8.4M trips / 3 tháng
 Postgres CDC (Debezium → Kafka)	Logical replication	Real-time

Output — 2 sản phẩm, 2 đối tượng


Sản phẩm	Format	Cho ai	Họ làm gì
 Golden Data	30 Parquet datasets	Data Engineers	Pipeline mới, train model, audit
 Superset Dashboard	PostgreSQL → 4 charts	Marketing, Sales, CEO	Quyết định kinh doanh

Slide 3: Hai luồng song song




	MAIN FLOW	MONITOR FLOW
Vai trò	Chạy pipeline, không thay đổi gì	DAG riêng, chỉ SELECT, không ghi
Tần suất	Monthly (batch)	@every 5 phút
Nếu fail	Pipeline dừng, phải retry	Slack + Email ngay
Phụ thuộc	Không phụ thuộc Monitor	Không ảnh hưởng MAIN

Slide 4: Pipeline — 13 nodes



Slide 5: Quality Gates — 5 gates, block pipeline



Cross-Node Reconciliation — đối chiếu xuyên tầng

```
spark_input rows == silver rows + quarantine rows
silver rows      == mart.fact_trips rows
mart.* rows     == gold_export.* rows
gold.* rows     == postgres.* rows
```

Mỗi cặp sai → block pipeline ngay.

Slide 6: Failure Mode → Detection → Ứng phó

#	Tình huống	Phát hiện bởi	Ứng phó
1	MinIO sai bucket → Spark đọc 0 rows	verify_silver: row_count = 0	Block trino_bootstrap
2	Spark type cast → fare_amount null	verify_silver: null_ratio > 0	Block trino_bootstrap
3	Spark crash → duplicate rows	verify_silver: row_count > expected	Block trino_bootstrap

#	Tình huống	Phát hiện bởi	Ứng phó
4	Trino OOM → gold export thiếu bảng	verify_gold: tables < 30	Block + alert
5	materialize fail → Postgres empty	verify_postgres: pg ≠ gold	Block superset
6	Superset cache → data cũ	verify_superset: chart stale	Slack warning
7	NYC không publish data mới	verify_freshness: max_date > 35d	Block analytics_check
8	Kafka consumer lag	check_kafka: lag > 1000	Slack + Email
9	MinIO disk gần đầy	check_minio: size > 2x avg	Slack warning

Slide 7: CDC Chain — Postgres → Debezium → Kafka → Streaming

Postgres CDC

Vấn đề	Fix	Tại sao
WAL không giới hạn → disk full	<code>max_wal_size=4GB</code> , <code>wal_keep_size=2GB</code>	Chặn DB crash
Replication slot mất → mất offset	Monitor slot active + lag	Phát hiện < 5 phút
Single point of failure	Dev: StatefulSet + backup. Production: RDS Multi-AZ	HA

Debezium

Vấn đề	Fix	Tại sao
Snapshot full table → lock DB	<code>snapshot.mode=schema_only</code>	Data đã có từ batch
Event lớn (before + after + schema)	<code>ExtractNewRecordState</code>	Giảm 70% event size

Vấn đề	Fix	Tại sao
Delete event mất	<code>delete.handling.mode=rewrite</code>	Có tombstone
Không monitor lag	Check <code>MillisecondsBehindSource</code> < 5 phút	Alert kịp thời

Kafka


Vấn đề	Fix	Tại sao
1 partition → 1 consumer	3 partitions	Spark parallel 3x
7d retention → mất offset	14 ngày + offset topic retention = -1	Recover được sau 1 tuần
Producer duplicate	<code>enable.idempotence=true</code> , <code>acks=all</code>	Retry không duplicate

Spark Streaming

Vấn đề	Fix	Tại sao
Ghi chung path với batch	Tách <code>nyc-silver/stream/trips</code>	Batch + stream độc lập
group_id random → duplicate	<code>group.id</code> cố định	Track offset qua restart
Poison pill → crash	DLQ topic + try-catch	Stream không chết
<code>trigger=availableNow</code> → không real-time	<code>processingTime=5min</code>	Continuous
Delete event mất	Soft delete <code>is_deleted=true</code>	dbt filter <code>WHERE is_deleted=false</code>

Vấn đề: 1 file Parquet sai schema → Spark crash cả batch. File sai tên → glob miss → thiếu data.

Giải pháp: `validate_raw_files.py` chạy trước `spark_batch`.



3 levels:

- 1. Path & format — `year=*/month=*/*.parquet`
- 2. Schema — đủ 19 cột Parquet bắt buộc
- 3. Duplicate — check etag, không xử lý lại file cũ

Slide 9: Trino — Chống OOM, tăng concurrency

Vấn đề	Fix
OOM khi gold_export 30 CTAS	Resource group: gold_export max 2 concurrent, 3GB/query
max 1 concurrent query	Tăng lên 5 concurrent
File-based metastore corrupt	Dev: backup PVC → S3. Production: Glue Catalog
Partition không tự sync	Auto sync sau spark_batch
Single node – không HA	Production: 1 coordinator + 2 workers
Không query monitoring	Monitor DAG check <code>system.runtime.queries</code>

Slide 10: dbt + Superset + Anomaly Check

dbt

Vấn đề	Fix
Không CI/CD — push thẳng	GitHub Actions: <code>dbt build --target staging</code> trên PR
Chỉ test not_null	Business assertion: SUM(revenue) cross-check
Scan toàn bộ 180M rows mỗi lần	Incremental model cho fact_trips
Không data lineage	<code>dbt docs generate</code> → host S3


Superset

Vấn đề	Fix
Bootstrap tạo duplicate	Check tồn tại trước khi tạo
Cache stale sau pipeline	API refresh dataset + chart sau materialize
Chart SQL không version	Lưu trong <code>superset/charts/</code> , PR review
admin/admin public	Env var + public user read-only

Anomaly Check

Vấn đề	Fix
exit code luôn 0 (info only)	Thêm flag <code>--block</code> để block pipeline
Chỉ check row count	Thêm fare, distance, revenue
Không alert	Slack webhook khi phát hiện
Threshold cứng	30-day rolling baseline $\pm 3\sigma$

Slide 11: Lộ trình — 5 phase



Tổng kết

Mục	Chi tiết
Hiện tại	Pipeline chạy ổn định, 8.4M trips, 3 DAGs, 12 pods
Hardening	5 phase, 10 tuần, 1-2 người
Mục tiêu	Tự phát hiện + ứng phó sự cố trong < 5 phút
Chi phí infra	+3-5 pod (Kafka cluster, Trino workers)