


NYC Taxi Data Pipeline

Slide deck — trình bày cho management

Slide 1: Title

NYC Taxi Data Pipeline

Batch & Streaming Data Engineering Platform



Slide 2: Bài toán


Input

Nguồn	Format	Volume
 NYC TLC Yellow Taxi (S3 Parquet)	Hive-partitioned	8.4M trips / 3 tháng
 Postgres CDC (Debezium → Kafka)	Logical replication	Real-time

Output — 2 sản phẩm, 2 đối tượng


Sản phẩm	Format	Cho ai	Họ làm gì
 Golden Data	30 Parquet datasets trên S3	Data Engineers	Build pipeline mới, train model, audit, export
 Superset Dashboard	PostgreSQL → 4 charts	Marketing, Sales, CEO	Quyết định kinh doanh


Slide 3: Kiến trúc — 2 luồng song song



2 luồng độc lập: MAIN chạy pipeline chính (monthly). MONITOR chạy song song (5 phút/lần), chỉ SELECT không ghi, phát hiện lỗi → Slack + Email. Monitor fail không ảnh hưởng MAIN.

Slide 4: Pipeline — 13 nodes






Spark Validation — 10 business rules

Rule	Mục đích
pickup_ts / dropoff_ts không null	Loại trip thiếu thời gian
dropoff_ts > pickup_ts	Loại trip thời gian âm
trip_distance > 0	Loại trip 0 km
fare_amount >= 0, total >= fare	Loại trip sai giá
passenger_count 1-6	Loại trip sai số ghế
payment_type 1-6	Loại sai phương thức
pickup/dropoff zone tồn tại	Loại location ID ảo

Slide 5: Quality Gates — tự động kiểm tra sau mỗi node



Cross-Node Reconciliation — đối chiếu dữ liệu xuyên suốt pipeline

```
spark_input == silver + quarantine → silver == mart.fact_trips → mart == gold → gold ==  
postgres
```

4 cặp đối chiếu. Sai bất kỳ cặp nào → block pipeline ngay. Đảm bảo không mất data giữa các tầng.


Slide 6: Monitor DAG — 10 checks, phát hiện trong 5 phút

Check	Kiểm tra gì	Alert nếu
check_silver	Row count, null ratio, distance	Row = 0 hoặc null > 0
check_streaming	Consumer lag, checkpoint	Lag > 1000
check_gold	30 tables tồn tại	Thiếu bảng
check_postgres	pg rows = gold rows	Mismatch
check_superset	Charts render OK	Chart không data
check_freshness	MAX(pickup_date) ≤ 35 ngày	Data stale
check_pg_cdc	WAL size, replication slot active	WAL > 3.5GB hoặc slot inactive
check_debezium	Connector RUNNING?, lag < 5 phút	Connector FAILED
check_kafka	Broker health, consumer lag	Lag > 10000
check_minio	Health endpoint, bucket size	Disk > 85%

Tất cả check → Slack + Email. Không cần đợi pipeline chạy mới biết hệ thống có vấn đề.


Slide 7: CDC Chain — Postgres → Debezium → Kafka → Spark Streaming

Postgres CDC




Config	Giá trị	Mục đích
max_wal_size	4GB	Chặn disk full
wal_keep_size	2GB	Debezium không mất offset khi lag
max_replication_slots	5	1 active + 1 spare
HA	RDS Multi-AZ (production)	Auto failover

Debezium




Config	Giá trị	Mục đích
snapshot.mode	schema_only	Không lock DB, data đã có từ batch
ExtractNewRecordState	Chỉ lấy after	Giảm 70% event size
delete.handling.mode	rewrite	Delete → tombstone, không mất
offset.storage.topic	nyc_cdc_offset	Offset không expire được

Kafka




Config	Giá trị	Mục đích
partitions	3	Spark parallel 3x
retention	14 ngày	Recover được sau 1 tuần
<code>enable.idempotence</code>	true	Retry không duplicate
<code>auto.create.topics</code>	false	Không tạo topic rác

Spark Streaming



Config	Giá trị	Mục đích
<code>failOnDataLoss</code>	true	Crash nếu mất offset — không nuốt lỗi
Trigger	<code>processingTime=5min</code>	Continuous, catch-up backlog
Silver path	<code>stream/trips</code> riêng	Batch + stream độc lập
cdc_bridge group	cố định <code>cdc-bridge-v1</code>	Không duplicate khi restart
Poison pill	Try-catch → DLQ	1 message hỏng không chết cả stream

Slide 8: Pre-ingest Validation — chặn file hỏng trước Spark



Level	Kiểm tra	Hành động
1	Path + format: <code>year=*/month=*/*.parquet</code>	Quarantine nếu sai
2	Schema: 19 cột Parquet bắt buộc	Quarantine nếu thiếu
3	Duplicate check bằng etag	Skip nếu đã xử lý

Chỉ 1 format được chấp nhận:

```
s3://nyc-raw/yellow_taxi/year=2024/month=01/yellow_tripdata_2024-01.parquet
```

Slide 9: Trino — Resource Groups + Batch CTAS

Tính năng	Config	Lợi ích
Resource Groups	gold_export: 2 concurrent × 3GB. adhoc: 3 concurrent × 2GB	Không OOM, dbt + Superset không phải chờ
Batch CTAS	30 tables → 3 batch × 10, nghỉ 30s giữa batch	Memory được GC kịp
Metastore	Dev: file-based + backup → S3. Production: Glue Catalog	Chống mất catalog
Auto partition sync	Sync sau spark_batch trước dbt_build	Trino thấy partition mới ngay
HA	1 coordinator + 2 workers (production)	Chết 1 worker vẫn chạy
Query monitoring	<code>system.runtime.queries</code> → alert FAILED/BLOCKED	Biết query nào gây OOM

Slide 10: dbt + Superset + Anomaly

dbt

Tính năng	Mô tả
CI/CD	GitHub Actions: <code>dbt build --target staging</code> trên mỗi PR
Incremental model	<code>fact_trips</code> chỉ đọc partition mới, không scan 180M rows
Business tests	Custom tests: SUM(revenue) cross-check giữa các model
dbt docs	Auto generate + host S3 sau mỗi build

Superset


Tính năng	Mô tả
Idempotent bootstrap	Check tồn tại trước khi tạo, không duplicate
Cache bust	API refresh dataset + chart sau mỗi pipeline
Chart version control	SQL lưu trong <code>superset/charts/</code> , PR required
Security	Admin bằng env var, public user read-only


Anomaly Check

Tính năng	Mô tả
Block optional	<code>--block</code> flag — block pipeline nếu anomaly > threshold
Multi-metric	Row count + fare + distance + revenue
Slack alert	Webhook kèm bảng anomaly
Baseline tự học	30-day rolling $\pm 3\sigma$

Slide 11: Spark Scalability + Crash Recovery

Spark tự động chọn chiến lược xử lý dựa trên tài nguyên:





Crash recovery: Spark ghi vào thư mục tạm `_tmp/` → ghi xong mới move vào thư mục chính. Crash không ảnh hưởng data cũ.

Slide 12: Hiện trạng

Con số

Hạng mục	Giá trị
Valid trips	8.4M
Invalid trips (quarantine)	1.07M (~11%)
dbt models	30 (staging → marts → gold)
dbt tests	54/54 PASS
BI datasets (gold layer)	30
Superset charts	4
Airflow DAGs	3 (monthly, weekly, CDC)
Total install	1 lệnh scaffold dev
Pipeline duration	< 45 phút

12 pods trên Kubernetes

Component	Pods
Airflow (scheduler + webserver + Postgres)	3
Postgres (CDC + Analytics)	2
Debezium + Kafka	2
MinIO	1
Spark (master + 2 worker)	3

Component	Pods
Trino	1
Superset	1
